

# **Numerical Algebra: Homework 10**

HUANG Wenchong

3200100006

May 7, 2022

2. 证: 将  $\varphi(x) = x^T A x - 2b^T x$  在  $x_{k-1}$  处 Taylor 展开得:

$$\begin{aligned}\varphi(x_k) &= \varphi(x_{k-1}) + \nabla^T \varphi(x_{k-1})(x_k - x_{k-1}) + \frac{1}{2} (x_k - x_{k-1})^T \nabla^2 \varphi(x_{k-1})(x_k - x_{k-1}) \\ &= \varphi(x_{k-1}) - 2r_{k-1}^T (\alpha_{k-1} r_{k-1}) + \alpha_{k-1}^2 (r_{k-1}^T A r_{k-1}) \\ &= \varphi(x_{k-1}) - \frac{(r_{k-1}^T r_{k-1})^2}{r_{k-1}^T A r_{k-1}}\end{aligned}$$

$$\begin{aligned}\text{又: } r_{k-1}^T A r_{k-1} &= (b - A x_{k-1})^T A (b - A x_{k-1}) \\ &= b^T A b + x_{k-1}^T A x_{k-1} - 2b^T x_{k-1} \\ &= b^T A b + \varphi(x_{k-1})\end{aligned}$$

$$\text{由 } A \text{ 正定} \Rightarrow A^T \text{ 正定} \Rightarrow b^T A b > 0 \Rightarrow \varphi(x_{k-1}) < r_{k-1}^T A r_{k-1}$$

$$\begin{aligned}\text{于是: } \varphi(x_k) &= \varphi(x_{k-1}) \left[ 1 - \frac{(r_{k-1}^T r_{k-1})^2}{\varphi(x_{k-1}) \cdot (r_{k-1}^T A r_{k-1})} \right] \\ &< \varphi(x_{k-1}) \left[ 1 - \frac{r_{k-1}^T r_{k-1}}{r_{k-1}^T A r_{k-1}} \cdot \frac{r_{k-1}^T r_{k-1}}{r_{k-1}^T A r_{k-1}} \right] \\ &< \varphi(x_{k-1}) \left( 1 - \frac{1}{\|A\|_2 \cdot \|A^{-1}\|_2} \right) = \left( 1 - \frac{1}{\kappa(A)} \right) \varphi(x_{k-1})\end{aligned}$$

□

3. 证: 设  $n+1$  步终止, 即  $x_{n+1} = x_*$ ,  $Ax_* - b = 0$ .

$$\text{由 } x_{n+1} = x_n + \alpha_n r_n, \text{ 得 } A(x_n + \alpha_n r_n) - b = 0.$$

$$\text{而 } r_n = b - Ax_n, \text{ 故 } b = Ax_n + r_n, \text{ 从而:}$$

$$\begin{aligned}A(x_n + \alpha_n r_n) - (Ax_n + r_n) &= 0 \\ \Rightarrow \alpha_n (Ar_n) = r_n &\Rightarrow Ar_n = \alpha_n^{-1} r_n\end{aligned}$$

即  $r_n$  是  $A$  的特征向量, 且  $\alpha_n^{-1}$  为对应的特征值.

□

6. 证: 记  $\phi(t) = \varphi(y_{i-1} + te_i)$ , 由凸函数的性质,  $\phi(t)$  取  $\min \Leftrightarrow \phi'(t) = 0$ .

$$\phi'(t) = e_i^T \nabla \varphi(y_{i-1} + te_i) = 2e_i^T (A(y_{i-1} + te_i) - b) = 2(e_i^T A y_{i-1} + t - e_i^T b)$$

$$\phi'(t) = 0 \Leftrightarrow t = e_i^T b - e_i^T A y_{i-1} = b_i - \sum_{j=1}^n a_{ij} y_j^{(k-1)} - \sum_{j=1}^n a_{ij} y_j^{(k)}$$

$$\text{如此更新 } y_i = y_{i-1} + te_i$$

与 G-S 迭代法中更新第  $k$  步的第  $i$  个分量格式相同.

故  $x_k$  就是 G-S 迭代第  $k$  步的结果. 此方法与 G-S 法相同.

□

7. 证: 由实对称性, 知存在以  $A$  的特征向量构成的  $\mathbb{R}^n$  空间基底.

设  $A$  有特征值  $\lambda_1, \dots, \lambda_k$ , 代数重数为  $m_1, \dots, m_k$ ,  $\lambda_i$  对应特征向量  $x_1^{(i)}, \dots, x_{m_i}^{(i)}$  (单位正交)

则,  $\forall r \in \mathbb{R}^n$ ,  $\exists \alpha_{ij} (1 \leq i \leq k, 1 \leq j \leq m_i)$ , 使

$$r = \sum_{i=1}^k \sum_{j=1}^{m_i} \alpha_{ij} x_j^{(i)}$$

从而:

$$A^s r = \sum_{i=1}^k \sum_{j=1}^{m_i} \alpha_{ij} \lambda_i^s x_j^{(i)}, \quad s = 1, 2, \dots, n-1$$

用归纳法证明  $\dim \text{span}(r, Ar, \dots, A^{n-1}r) \leq k$ .

首先, 若  $k=1$ . 假定有  $\beta_1, \dots, \beta_n \in \mathbb{R}$ , 使

$$\beta_1 r + \beta_2 Ar + \dots + \beta_n A^{n-1}r = 0$$

$$\text{i.e. } 0 = \sum_{s=1}^n \beta_s A^{s-1} r = \sum_{s=1}^n \beta_s \sum_{j=1}^m \alpha_{ij} \lambda_i^{s-1} x_j^{(i)}$$

取  $j=1, \dots, m, n$ , 上式两边同乘  $x_j^{(i)T}$  得:

$$0 = \sum_{s=1}^n \beta_s \alpha_{ij} \lambda_i^{s-1} x_j^{(i)T} x_j^{(i)} = \sum_{s=1}^n \beta_s \alpha_{ij} \lambda_i^{s-1}$$

$$\Rightarrow \begin{pmatrix} \alpha_{i1} & \alpha_{i1}\lambda_i & \dots & \alpha_{i1}\lambda_i^{n-1} \\ \alpha_{i2} & \alpha_{i2}\lambda_i & \dots & \alpha_{i2}\lambda_i^{n-1} \\ \vdots & \vdots & \ddots & \vdots \\ \alpha_{in} & \alpha_{in}\lambda_i & \dots & \alpha_{in}\lambda_i^{n-1} \end{pmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_n \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

系数矩阵显然秩不大于 1, 故解空间维数不小于  $n-1$

这表明  $\dim \text{span}(r, Ar, \dots, A^{n-1}r) \leq 1$ .

现假设结论对  $1, 2, \dots, k-1$  已成立, 考虑  $k$  ( $k \geq 2$ ).

同样假定  $\beta_1, \dots, \beta_n \in \mathbb{R}$ , 使:

$$\beta_1 r + \beta_2 Ar + \dots + \beta_n A^{n-1}r = 0$$

由归纳假设,  $\begin{pmatrix} A_1 \\ \vdots \\ A_{k-1} \end{pmatrix} \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_n \end{pmatrix} = \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix}$ , 其中  $A_i = \begin{pmatrix} \alpha_{i1} & \alpha_{i1}\lambda_i & \dots & \alpha_{i1}\lambda_i^{m-1} \\ \alpha_{i2} & \alpha_{i2}\lambda_i & \dots & \alpha_{i2}\lambda_i^{m-1} \\ \vdots & \vdots & \ddots & \vdots \\ \alpha_{im} & \alpha_{im}\lambda_i & \dots & \alpha_{im}\lambda_i^{m-1} \end{pmatrix}$

总有  $\text{rank}(A_i) \leq 1$ , 故解空间维数不小于  $n-(k-1)$ . 而  $\text{rank}(A_k) \leq 1$  也成立

$$\Rightarrow \begin{pmatrix} A_1 \\ \vdots \\ A_k \end{pmatrix} \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_n \end{pmatrix} = \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix} \quad \text{解空间维数不小于 } n-k$$

这表明  $\dim \text{span}(r, Ar, \dots, A^{n-1}r) \leq k$ .

由归纳法即得证.

□

8. 证: 共轭梯度法产生的向量组  $\{r_0, \dots, r_k\}$  是 Krylov 子空间:

$$\text{span}\{r_0, Ar_0, \dots, A^{n-1}r_0\}$$

的正交基. 而由 Ex7. 知 Krylov 子空间维数至多为 1 (互异特征值的个数)

故  $k \leq l-1$ . 即最多迭代  $l$  步.

□

# 1 上机题报告

## 1.1 CG 方法通用子程序设计

```
function [x,step] = CG(A,b,err)
    x = zeros(size(A,1),1);
    r = A*x-b;
    p = -r;
    step = 0;
    while vecnorm(r) >= err
        step = step + 1;
        alpha = - (r.'*p)/(p.'*A*p);
        x = x + alpha*p;
        tmp = r.'*r;
        r = r + alpha*A*p;
        beta = (r.'*r)/tmp;
        p = -r + beta*p;
    end
end
```

## 1.2 数值实验 - 上机习题 5.2

用 Hilbert 矩阵测试共轭梯度法：

$$a_{ij} = (i + j + 1)^{-1}, \quad b_i = \frac{1}{3} \sum_{j=1}^n a_{ij} \quad (1 \leq i, j \leq n)$$

我们给定  $N = 100$ ，对  $n = 1, 2, \dots, N$  阶的 Hilbert 矩阵，用 CG 方法求解线性方程组，停机准则设为：

$$\|r_k\|_2 < err = 10^{-14}$$

求解后将结果与精确解进行比较，绘制残差关于阶数的图线。同时，观察迭代次数，绘制迭代次数关于阶数的图线。代码如下（附件 ex\_5\_2.m）：

```
N = 100;
index = zeros(N,1);
err = zeros(N,1);
step = zeros(N,1);
for n = 1:N
    A = hilb(n);
    b = zeros(n,1);
    for i = 1:n
        b(i) = sum(A(i,1:n))/3;
    end
    index(i) = i;
    [x,step(i)] = CG(A,b,1e-14);
```

```

    err(i) = vecnorm(x-ones(n,1)/3);
end
subplot(1,2,1)
plot(index, err);
xlabel('(1) residual of n','fontname', 'Times new roman','interpreter', 'latex');
box off
subplot(1,2,2)
plot(index, step);
xlabel('(2) iterations of n','fontname', 'Times new roman','interpreter', 'latex');
box off

```

测试结果如下图所示：




图 1: 用 CG 法解 Hilbert 矩阵方程，残差与迭代次数关于阶数  $n$  的图线

### 1.3 数值实验 - 上机习题 5.3

使用 Jacobi 迭代法、G-S 迭代法和共轭梯度法求解下述方程：

$$\begin{bmatrix} 10 & 1 & 2 & 3 & 4 \\ 1 & 9 & -1 & 2 & -3 \\ 2 & -1 & 7 & 3 & -5 \\ 3 & 2 & 3 & 12 & -1 \\ 4 & -3 & -5 & -1 & 15 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix} = \begin{bmatrix} 12 \\ -27 \\ 14 \\ -17 \\ 12 \end{bmatrix}$$

容易知道上述方程的精确解为  $(1, -2, 3, -2, 1)^T$ 。现分别用三种迭代法求解，与精确解做误差比较，并输出迭代次数。测试用代码如下（附件 ex\_5\_3.m）：

```

A = [[10 1 2 3 4]; [1 9 -1 2 -3]; [2 -1 7 3 -5]; [3 2 3 12 -1]; [4 -3 -5 -1 15]];
b = [12; -27; 14; -17; 12];
s = [1; -2; 3; -2; 1];
eps = 1e-12;
[x1, step1] = jacobi(A, b, eps);
[x2, step2] = gauss_seidel(A, b, eps);
[x3, step3] = CG(A, b, eps);
solutions = [x1 x2 x3]
residures = [vecnorm(x1-s) vecnorm(x2-s) vecnorm(x3-s)]
iterations = [step1 step2 step3]

```

输出结果如下（从左到右分别为 Jacobi 迭代、G-S 迭代、CG 方法的结果）：

```
solutions =

    1.000000000000183    0.999999999999123    1
   -2.000000000000168   -1.99999999999928   -2
    2.999999999999692    3.000000000000125    3
   -1.99999999999951   -2.00000000000012   -2
    0.9999999999997802    1.000000000000079    1

residues =

    4.55356206907407e-12    1.86230250377141e-12    1.11022302462516e-15

iterations =

    138    80    5
```

可以看到，Jacobi 迭代和 G-S 迭代所花费的迭代次数远远高于共轭梯度法，而且所得解的精度也不如共轭梯度法。事实上，我们可以计算 Jacobi 迭代法和 G-S 迭代法的渐进收敛速度：

$$R_{\infty}(M^{(Jacobi)}) = -\ln \rho(M^{(Jacobi)}) = -\ln 0.826786 = 0.19$$

$$R_{\infty}(M^{(G-S)}) = -\ln \rho(M^{(G-S)}) = -\ln 0.684558 = 0.38$$

对于共轭梯度法我们有收敛性估计：

$$\|x_* - x_k\|_A \leq 2 \left( \frac{\sqrt{\kappa_2} - 1}{\sqrt{\kappa_2} + 1} \right)^k \|x_* - x_0\|_A$$

类似地我们可以计算：

$$-\ln \left( \frac{\sqrt{\kappa_2} - 1}{\sqrt{\kappa_2} + 1} \right) = -\ln 0.545826 = 0.605$$

这个值高于 Jacobi 迭代法和 G-S 迭代法的渐进收敛速度。而且由于上式对共轭梯度法的收敛速度给出的估计是十分粗糙的，共轭梯度法实际计算时，收敛速度还要比它快得多。所以共轭梯度法在三者的比较中占据绝对优势完全是预料之中的。